

LAPORAN PROYEK NLP DANA

DATA ANALYST

PERTEMUAN 21 Agustus 2026



NAMA

Muhammad Yahya Ayyasy

INSTRUKTUR

Kusuma Ade

PPKD JAKARTA SELATAN

ANGKATAN 2

2026

I. Latar Belakang Masalah

DANA merupakan salah satu platform dompet digital terbesar di Indonesia dengan jutaan transaksi harian. Tingginya aktivitas operasional ini rentan terhadap kendala teknis (seperti transfer *pending* atau saldo tertahan) yang seringkali berujung pada keluhan pelanggan di kanal publik seperti Google Play Store. Proyek ini bertujuan menganalisis sentimen keluhan tersebut menggunakan metode *Natural Language Processing* (NLP). Analisis ini digunakan untuk melatih algoritma agar dapat memahami konteks masalah secara spesifik. Lebih jauh, hasil pemodelan ini diimplementasikan menjadi *Automated Resolution Center* (Chatbot AI) guna merespons keluhan secara otomatis, mereduksi waktu penanganan, dan memberikan tindakan preventif pada laporan indikasi kecurangan (*fraud*).

II. Sumber Data & Proses Scraping

- **Platform:** Google Play Store (App ID: id.dana).
- **Data Terkumpul:** Berhasil diekstraksi sebanyak **11.000 ulasan** dengan rentang waktu 1 Maret 2026 hingga 23 Agustus 2026.
- **Kendala:** Tidak ada pemblokiran *rate-limit* dari platform. Kendala utamanya adalah teks mentah sangat "kotor" (banyak singkatan *e-wallet*, kalimat pendek, dan emoji). Solusi yang diterapkan adalah normalisasi teks menggunakan *custom slang dictionary* (misal: "wd" menjadi "tarik", "tf" menjadi "transfer") sebelum tahap *cleaning*.

III. Strategi Pelabelan

Pelabelan sentimen (*Ground Truth*) dilakukan menggunakan pendekatan Semi-Otomatis:

- **Lexicon yang Digunakan:** Pembuatan kamus kata (Lexicon) dirancang khusus untuk industri dompet digital, memuat 48 kata positif (seperti: praktis, lancar, canggih) dan 58 kata negatif (seperti: error, ngelag, lelet, penipu). Sistem juga dilengkapi penanganan negasi (*Negation Handling*) pada kata "tidak", "bukan", dan sejenisnya untuk mendeteksi pembalikan sentimen.
- **Koreksi Manual:** Pengujian lexicon awal menunjukkan bias. Evaluasi manual pada 50 baris menemukan 5 kesalahan klasifikasi akibat majas sarkasme dan kalimat bersyarat (contoh: "sengaja kasih bintang 5 biar di lihat developer , aplikasi ini sangat lemah dalam sistem keamanan" yang awalnya dilabeli "Netral", dikoreksi menjadi "Negatif"). Setelah koreksi manual dan penyesuaian lexicon, dihasilkan **7.948** baris dataset bersih dengan dua kelas (2.671 baris positif, 5.277 baris negatif).

IV. Tahapan Preprocessing

Proses pembersihan dan standarisasi teks diimplementasikan dalam lima tahap sistematis:

- **Case Folding:** Mengubah seluruh karakter menjadi huruf kecil.
- **Cleaning dengan Regex:** Pembersihan ekspresi reguler terhadap URL, penyebutan (*mention @*), tanda pagar (*hashtag #*), angka, karakter non-alfanumerik, dan spasi ganda.

- **Normalisasi Teks:** Penggunaan kamus *slang* (sebagaimana dijabarkan pada bagian 2).
- **Stop Word Removal:** Penghapusan kata tugas dan kata depan yang tidak memiliki kontribusi leksikal menggunakan *Sastrawi StopWordRemoverFactory*.
- **Stemming:** Pemotongan kata berimbuhan menjadi bentuk dasar menggunakan *Sastrawi StemmerFactory* untuk mereduksi keunikan dimensi kosa kata.

V. Hasil Ekstraksi Fitur

- Perbandingan BoW vs TF-IDF: Bag of Words (BoW) sekadar menjumlahkan frekuensi kata, sehingga kata keterangan yang umum muncul namun tidak terlalu penting untuk menentukan sentimen tetap mendapat bobot besar. Sebaliknya, metode *Term Frequency - Inverse Document Frequency* (TF-IDF) memberi penalti matematis pada kata yang terlalu umum, sehingga mampu mengekstrak istilah-istilah yang lebih unik, spesifik, dan krusial pada konteks industri dompet digital.
- **10 Kata Terpenting (Skor TF-IDF):** Berdasarkan komputasi TF-IDF, 10 bobot kata tertinggi adalah: "dana" (0.0757), "aplikasi" (0.0496), "sangat" (0.0456), "nya" (0.0450), "transaksi" (0.0420), "guna" (0.0336), "gak" (0.0322), "bagus" (0.0311), "di" (0.0310), dan "uang" (0.0309).

VI. Hasil Klasifikasi (Rangkuman Model)


Model	Akurasi	F1-Score	Kecepatan	Cocok untuk
Naïve Bayes	0.8931	Positif: 0.82 Negatif: 0.92	Cepat / Ringan	Analisis cepat dan <i>baseline benchmark</i> .
SVM (LinearSVC)	0.9333	Positif: 0.90 Negatif: 0.95	Cukup Cepat	Analisis teks multi-konteks / Produksi Chatbot.
DistilBERT	0.8541	Positif: 0.78 Negatif: 0.90	Relatif Lambat	<i>Zero-shot analysis</i> (namun butuh <i>fine-tuning</i>).

VII. Visualisasi WordCloud



Pemisahan representasi *WordCloud* mengonfirmasi akar sentimen pengguna secara transparan. Pada ulasan **Positif**, leksikon tertinggi mencakup "mudah" (774 frekuensi), "transaksi" (729), "guna" (629), dan "bantu" (618). Ini mencerminkan validitas UI/UX DANA yang *user-friendly* dalam memproses transaksi harian. Di sisi **Negatif**, sorotan tertinggi terpaku pada "transaksi" (1.604), "mau" (1.540), "saldo" (1.525), dan "akun" (1.252). Dominasi kata "saldo" yang dibarengi tingkat F1-Score model SVM untuk ulasan negatif (0.95) menyimpulkan bahwa mayoritas komplain berakar pada kecemasan pengguna terkait keamanan saldo dan kegagalan (*error/bug*) transfer.

VIII. Chatbot yang Dibangun dan Cara Deploy di XAMPP



Purwarupa "**DANA Automated Resolution Center**" di-deploy secara terintegrasi pada server lokal XAMPP (Apache, Port 80) pada direktori C:\xampp\htdocs\chatbot\. Arsitekturnya berpusat pada algoritma *Hybrid NLP Routing*. Layer pertama mengandalkan skrip fungsional PHP (*chat.php*) untuk mendeteksi intent berbasis *rule-matching* serta *Regex* (pencarian format Ticket ID DANA-xxx). Jika intent tersebut gagal merespons kerumitan pertanyaan pelanggan, *engine* akan secara otomatis memanggil *Fallback Layer* melalui *cURL* ke *endpoint* *APIPythonFlask*(http://127.0.0.1:5000/predict). Di server Flask ini, *Support Vector Machine* (SVM) yang telah dilatih mengevaluasi teks keluhan dan merespons berdasarkan probabilitas sentimennya.

No	Nama Intent	Pola yang Dikenali	Contoh Respon
1	apresiasi	'terbaik', 'mantap', 'keren', 'luar biasa',	"Wah, terima kasih banyak atas apresiasi dan kata-kata

No	Nama Intent	Pola yang Dikenali	Contoh Respon
		'bagus', 'terima kasih', 'apresiasi', 'masha allah', 'alhamdulillah', 'membantu'	positifnya Kak! 🥰 Kami akan terus berinovasi memberikan layanan dompet digital terbaik untuk Indonesia."
2	kompetitor	'gopay', 'shopeepay', 'ovo', 'spay', 'linkaja', 'mending gopay', 'mending ovo'	"Terima kasih atas masukannya Kak! Saran dan perbandingan dari pengguna akan menjadi data analitik berharga bagi tim Product DANA untuk meningkatkan kapabilitas sistem kami. 🚀"
3	informasi_pending	'masa pending', 'berapa lama pending', 'lama nunggu', 'status pending', 'sedang diproses'	"Status **Pending** atau Sedang Diproses berarti transaksi Kakak sedang mengantre di jalur komunikasi (switching) Bank Indonesia atau partner kami. SLA (Standard Level Agreement) untuk penyelesaian adalah maksimal **1x24 Jam Hari Kerja** ."
4	topup_saldo	'top up', 'topup', 'isi saldo', 'tambah saldo', 'cara isi']	"Untuk Top Up Saldo DANA, Kakak bisa menggunakan fitur **Transfer Bank (BCA, Mandiri, BRI, BNI)** , **Agen Pegadaian** , **Alfamart** , atau **Kantor Pos** . Buka menu 'Isi Saldo' di halaman utama aplikasi. 💰"
5	saldo_nyangkut	'nyangkut', 'terpotong', 'kepotong', 'uang ga masuk', 'belum masuk', 'hilang', 'ilang'	"Kami mengerti kekhawatiran Kakak. ⚠️ Jika terjadi antrean jaringan, saldo akan disesuaikan otomatis maksimal 1x24 jam

No	Nama Intent	Pola yang Dikenali	Contoh Respon
			kerja.\n\n 🗑️ **TICKET ID: DANA-" . date("Ymd") . "-" . rand(1000, 9999) . ***\nSimpan nomor tiket ini untuk eskalasi ke Live Agent."
6	transfer_bank	'transfer ke', 'kirim uang', 'tf bank', 'transfer mandiri', 'transfer bca'	"Untuk kendala transfer ke Bank, pastikan akun sudah terverifikasi **DANA Premium**. Kuota gratis transfer bank berlaku 10x/bulan. Jika limit habis, akan dikenakan biaya admin Rp2.500/transaksi."
	qris_error	'qris error', 'scan error', 'qris muter', 'gagal bayar qris', 'gagal scan'	"Jika Kakak mengalami gagal saat scan QRIS, hal ini biasanya karena QR Code kadaluarsa atau API koneksi tidak stabil. Saran kami: pastikan versi aplikasi DANA adalah yang terbaru dan bersihkan cache aplikasi. 🗑️ "
	security_fraud	'bocor', 'tersebar', 'disalah gunakan', 'disalahgunakan', 'dihack', 'dibajak', 'penipuan', 'scam', 'ditipu', 'bajak', 'otp saya', 'minta otp', 'login orang lain'	" 🚨 **SISTEM PERINGATAN DARURAT (FRAUD ALERT)** 🚨 \nKami mendeteksi anomali pada laporan keamanan Kakak. DANA tidak pernah meminta PIN/OTP.\n\nSistem kami telah menandai (flagging) laporan ini. Segera hubungi Call Center Darurat **1500445** agar kami dapat melakukan _Freeze Account_ (Pembekuan Akun)."

No	Nama Intent	Pola yang Dikenali	Contoh Respon
	akun_beku	'dibekukan', 'beku', 'diblokir', 'blokir'	"Sistem keamanan DANA otomatis membekukan akun jika mendeteksi anomali login (seperti pindah perangkat berulang kali). 🛑 \n\n **TICKET ID: SEC-" . date("Ymd") . "-" . rand(1000, 9999) . "***\nKirim email ke help@dana.id dengan subjek 'Pemulihan Akun [Nomor Tiket]' beserta Swafoto KTP."

IX. Kesimpulan dan Pembelajaran

Berdasarkan implementasi proyek dari modul prapemrosesan hingga integrasi model *Machine Learning*, tiga kesimpulan analitik yang ditarik adalah:

1. **Dampak Kualitas Preprocessing terhadap Akurasi Leksikon:**
Penyusunan kamus pengganti (*slang normalization*) spesifik dompet digital (misal, "wd", "tf", "nyangkut") serta penanganan negasi (*negation handling*) terbukti krusial. Tanpa intervensi tersebut, performa *TF-IDF* dapat merosot drastis karena *noise* teks dan kegagalan pendeteksian konteks leksikal.
2. **Keunggulan Model Klasik Terarah (*Tailored Machine Learning*):**
Dalam kasus ini, algoritma klasik SVM mampu mencapai Akurasi F1-Score sebesar 95% untuk deteksi keluhan sentimen (negatif), jauh melampaui pre-trained *Language Model* seperti RoBERTa (Akurasi 85.41%). Ini menunjukkan efisiensi metode *Term Frequency* yang dilatih dari kumpulan teks (*corpus*) kustom, dibandingkan *Deep Learning* yang belum melalui tahapan *fine-tuning* pada struktur *slang* bahasa Indonesia.
3. **Pendekatan Integrasi Hybrid untuk Stabilitas Operasional:**
Pengandalan semata pada deteksi kecerdasan buatan rentan menelurkan interpretasi membingungkan pada keluhan yang membutuhkan prosedur prosedural ketat (SOP standar perbankan). Integrasi metode gabungan (*Hybrid Routing*) di mana *Rule-based* mendikte prosedur, sedangkan *Machine Learning* menutupi area ketidaktahuan (*blind-spots*) terbukti sangat stabil sebagai fondasi arsitektur produk skala industri (*Enterprise*).